

Projekt badawczy

Przewodnik po wykładzie · dane: TeachingRatings (n = 463)

Spis treści

1	Od ciekawości do celu	2
1.1	Podgląd danych	2
1.2	Wiązka tropów	2
2	Hipotezy jako tropy	3
3	Co właściwie mierzymy?	5
4	Konspekt pracy badawczej	6
4.1	Cztery części konspektu	6
4.2	Wypełniony konspekt dla naszych danych	6
5	Pierwsze sprawdzenia	9
5.1	Tablica tropów po pierwszych testach	14
6	Wynik nie kończy badania	15
6.1	Co możemy policzyć dla tropów?	15
6.2	Zmienne zakłócające	16
7	Model kontrolny	18
7.1	Seria modeli kontrolnych	18
8	Od konspektu do wniosku	19
8.1	Co dopisać po analizie?	19
8.2	Zdanie, które warto mieć w raporcie	20
8.3	Domknięty projekt: cel + wiązka + werdykty	20

Cel badawczy: Czy ocena z ankiety (*eval*) mierzy jakość nauczania, czy raczej mieszankę jakości zajęć, sympatii, stereotypów i okoliczności kursu?

Tego pytania nie rozstrzyga pojedynczy test. Realizujemy go **wiązką 5 tropów** — konkurujących hipotez, które razem oświełają cel. Dane: 463 ewaluacje kursów akademickich (*AER::TeachingRatings*). Jedna obserwacja to jeden kurs; ten sam prowadzący może pojawić się przy kilku kursach.

1 Od ciekawości do celu

Projekt badawczy zaczyna się przed testem: od celu i zestawu konkurujących tropów, które ten cel pomogą wyjaśnić. Cel powstaje przez zawężanie:

Etap	Treść
Pomysł badawczy	Zaczynamy od przypuszczenia: ocena z ankiety może mieć kilka źródeł.
Cel badania	Formułujemy pytanie, które da się rozważyć na danych.
Plan analizy	Zamieniamy cel na hipotezy, zmienne i porównania.

Kolejność pracy: **najpierw cel i tropy, potem dobór metody statystycznej**. Test jest narzędziem do sprawdzenia tropu, nie punktem wyjścia.

1.1 Podgląd danych

Tabela 2: Pierwsze 10 wierszy zbioru (kluczowe zmienne)

eval	beauty	gender	age	minority	native	division	credits	students	allstudents	response.rate
4.3	0.29	kobieta	36	tak	tak	wyższy	więcej niż 1	24	43	55.8
4.5	-0.74	mężczyzna	59	nie	tak	wyższy	więcej niż 1	17	20	85.0
3.7	-0.57	mężczyzna	51	nie	tak	wyższy	więcej niż 1	55	55	100.0
4.3	-0.68	kobieta	40	nie	tak	wyższy	więcej niż 1	40	46	87.0
4.4	1.51	kobieta	31	nie	tak	wyższy	więcej niż 1	42	48	87.5
4.2	0.59	mężczyzna	62	nie	tak	wyższy	więcej niż 1	182	282	64.5
4.0	-0.13	kobieta	33	nie	tak	wyższy	więcej niż 1	33	41	80.5
3.4	-0.26	kobieta	51	nie	tak	wyższy	więcej niż 1	25	41	61.0
4.5	0.15	kobieta	33	nie	tak	wyższy	więcej niż 1	48	60	80.0
3.9	0.54	mężczyzna	47	nie	tak	wyższy	więcej niż 1	16	19	84.2

Jak czytać tabelę: **eval** — ocena kursu (wynik); **beauty** — ocena atrakcyjności (trop główny); **gender**, **minority**, **native**, **tenure** — cechy prowadzącego; **division**, **credits** — kontekst kursu; **students** / **allstudents** — liczba odpowiedzi i zapisanych; **response.rate** — odsetek odpowiedzi na ankietę; **prof** — identyfikator prowadzącego.

1.2 Wiązka tropów

Pięć tropów, które śledzimy przez cały wykład — rozważamy je wszystkie naraz, a nie pojedynczo:

Tabela 3: Wiązka tropów — stan początkowy

Trop	Pytanie	Narzędzie
Atrakcyjność	Czy prowadzący oceniani jako atrakcyjniejsi dostają wyższe oceny kursu?	korelacja Pearsona

Tabela 3: Wiązka tropów — stan początkowy (*continued*)

Trop	Pytanie	Narzędzie
Płeć	Czy kobiety i mężczyźni prowadzący są oceniani podobnie?	test t dla dwóch grup
Native speaker	Czy status native speaker wiąże się z oceną kursu?	Mann-Whitney
Mniejszość	Czy prowadzący z grup mniejszościowych są oceniani inaczej?	Mann-Whitney
Response rate	Czy przy niskim odsetku odpowiedzi ocena kursu znaczy to samo?	korelacja Pearsona

Poza naszą wiązką istnieją inne możliwe tropy: wielkość kursu, pora zajęć, trudność i obciążenie pracą, dyscyplina/wydział, powtarzalność prowadzącego. Wybór pięciu tropów to decyzja badawcza; zasadą przy własnym projekcie jest dążenie do wyczerpania tematu.

2 Hipotezy jako tropy

Hipoteza to robocze przypuszczenie o związku między zmiennymi. Projekt badawczy obejmuje kilka hipotez pod wspólnym celem — każda ma własne pytanie, roboczą hipotezę i alternatywne wyjaśnienia. Dopisujemy też część konspektową: czy mamy dane potrzebne do sprawdzenia alternatywnego wyjaśnienia i co trzeba uwzględnić w analizie. Na tym etapie nie wybieramy jeszcze testu — porządkujemy projekt.

Zasada: do każdej hipotezy podajemy co najmniej jedno alternatywne wyjaśnienie. Potem sprawdzamy, czy mamy dane, które pozwolą je odróżnić od głównego tropu. Brak danych nie przekreśla projektu, ale musi trafić do konspektu jako ograniczenie.

2.0.1 Trop: Atrakcyjność

Pytanie: Czy prowadzący oceniani jako atrakcyjniejsi dostają wyższe oceny kursu?

Robocza hipoteza: Wyższe `beauty` współwystępuje z wyższym `eval`.

Alternatywne wyjaśnienia:

- Atrakcyjność może być powiązana z wiekiem lub płcią.
- Studenci mogą wyżej oceniać osoby bardziej pewne siebie, a nie wygląd sam w sobie.
- Efekt może zależeć od typu kursu.

Czy mamy dane? Mamy `beauty`, `age`, `gender` oraz cechy kursu (`division`, `credits`). Nie mamy bezpośredniej miary pewności siebie ani stylu prowadzenia.

Co wpisać do konspektu? Sprawdzić związek `beauty` z `eval`, a potem uwzględnić wiek, płeć i typ kursu jako możliwe wyjaśnienia poboczne.

2.0.2 Trop: Płeć

Pytanie: Czy kobiety i mężczyźni prowadzący są oceniani podobnie?

Robocza hipoteza: Średnie `eval` różni się między grupami `gender`.

Alternatywne wyjaśnienia:

- Kobiety i mężczyźni mogą prowadzić inne typy kursów.
- Różnice mogą wynikać z oczekiwań studentów wobec stylu prowadzenia.
- Nierówny response rate może zmieniać obraz.

Czy mamy dane? Mamy `gender`, `eval`, cechy kursu oraz `response.rate`. Nie mamy danych o oczekiwaniach studentów ani stylu komunikacji prowadzącego.

Co wpisać do konspektu? Porównać oceny między grupami i sprawdzić, które cechy kursu oraz reprezentatywność odpowiedzi trzeba uwzględnić przy interpretacji.

2.0.3 Trop: Native speaker

Pytanie: Czy status native speaker wiąże się z oceną kursu?

Robocza hipoteza: Średnie `eval` różni się między `native = tak` i `native = nie`.

Alternatywne wyjaśnienia:

- Status native może mieszać się z typem kursu.
- Native speakerzy mogą uczyć innych przedmiotów albo na innym poziomie.
- Grupy mogą mieć różną liczebność.

Czy mamy dane? Mamy `native`, `division`, `credits` i liczebności grup. Nie mamy informacji o języku prowadzenia, poziomie trudności materiału ani doświadczeniu językowym studentów.

Co wpisać do konspektu? Sprawdzić, czy grupy różnią się oceną, oraz uwzględnić kontekst kursu i ostrożność przy nierównych liczebnościach.

2.0.4 Trop: Mniejszość

Pytanie: Czy prowadzący z grup mniejszościowych są oceniani inaczej?

Robocza hipoteza: Średnie `eval` różni się między `minority = tak` i `minority = nie`.

Alternatywne wyjaśnienia:

- Grupa mniejszościowa może być mało liczna — trudniej o stabilny wynik.
- Różnice mogą ujawniać się tylko w wybranych typach kursów.
- Status mniejszości może współwystępować z innymi cechami prowadzącego.

Czy mamy dane? Mamy `minority`, `eval` i kilka cech prowadzącego/kursu. Nie mamy danych o doświadczeniach dyskryminacji, atmosferze zajęć ani treści komentarzy studentów.

Co wpisać do konspektu? Opisać liczebności grup, porównać oceny i sprawdzić, czy wynik nie wynika z innych cech kursu lub prowadzącego.

2.0.5 Trop: Response rate

Pytanie: Czy przy niskim odsetku odpowiedzi ocena kursu znaczy to samo?

Robocza hipoteza: `response.rate` współwystępuje z `eval`.

Alternatywne wyjaśnienia:

- Odpowiadają głównie osoby skrajnie zadowolone lub niezadowolone.
- Duże kursy mogą mieć niższy response rate.
- Zaangażowanie grupy może wpływać i na oceny, i na odsetek odpowiedzi.

Czy mamy dane? Mamy `response.rate`, `students`, `allstudents` i `eval`. Nie mamy informacji, kto dokładnie odpowiedział ani dlaczego część osób pominęła ankietę.

Co wpisać do konspektu? Sprawdzić, czy odsetek odpowiedzi wiąże się z oceną i czy wielkość kursu zmienia interpretację tego związku.

3 Co właściwie mierzymy?

Pojęcie z hipotezy i zmienna w danych to nie to samo. Trzeba nazwać tę różnicę, zanim zinterpretujemy wynik. Cel mówi o *jakości nauczania*, ale w danych mamy tylko `eval`. Zanim ruszymy z testami, nazwijmy tę szczelinę.

Tabela 4: Pojęcie → wskaźnik → zmienna → ograniczenie

Pojęcie	Wskaźnik	Zmienna	Ograniczenie
Jakość nauczania: czy zajęcia realnie pomagają studentom uczyć się.	Ogólna ocena kursu wystawiona przez studentów.	eval: skala 1–5.	Może mierzyć satysfakcję, łatwość lub sympatię — nie faktyczne uczenie się.
Atrakcyjność jako możliwe źródło obciążenia ocen.	Średnia ocena wyglądu przez panel studentów.	beauty: wystandaryzowana.	To ocena społeczna, nie obiektywna cecha osoby.
Sprawiedliwość oceniania prowadzących.	Porównanie ocen między grupami prowadzących.	gender, native, minority, tenure.	Przynależność do grupy to etykieta, nie pomiar samego traktowania.
Reprezentatywność opinii studentów.	Odsetek zapisanych osób, które wypełniły ankietę.	response.rate.	Nie wiemy, kto nie odpowiedział i dlaczego.

Ważne rozróżnienie: możemy testować różnice w `eval`, ale `eval` nie jest tym samym co jakość nauczania. Wniosek musi mówić językiem zmiennych, a nie tylko językiem ambicji badawczych.

Pytania kontrolne do własnych projektów:

- Czy zmienna naprawdę mierzy to, o czym mówi hipoteza?
- Kto i kiedy wykonał pomiar?
- Jakie zjawisko mogłoby dać taki sam wynik w danych?

4 Konspekt pracy badawczej

Po celu, tropach i operacjonalizacji możemy zapisać pełny plan badania: zmienne, hipotezy, alternatywne wyjaśnienia i sposób interpretacji. Konspekt nie jest jeszcze raportem i nie jest listą testów. To roboczy plan — powinien być na tyle konkretny, żeby po jego przeczytaniu było wiadomo, co dokładnie będziemy sprawdzać w danych.

4.1 Cztery części konspektu

Krok	Element	Co zawiera
1	Cel badania	Jedno główne pytanie, które porządkuje cały projekt.
2	Zmienne, dane i pomiar	Źródło danych, jednostka obserwacji, zmienna wynikowa, zmienne główne, zmienne kontekstowe, ograniczenia pomiaru.
3	Tropy i hipotezy	Każdy trop ma pytanie, hipotezę roboczą, alternatywne wyjaśnienia oraz informację, czy mamy dane potrzebne do ich sprawdzenia.
4	Plan interpretacji	Co opiszemy, co porównamy, które zmienne uwzględnimy jako kontekst i jak ostrożnie połączymy wyniki z celem badania.

4.2 Wypełniony konspekt dla naszych danych

1. Cel badania

Sprawdzić, czy ocena z ankiety **eval** mierzy jakość nauczania, czy raczej miesza jakość zajęć, sympatię, stereotypy i okoliczności kursu.

2. Zmienne, dane i pomiar

Jednostką obserwacji jest kurs/ewaluacja. Dane zawierają oceny studenckie, cechy prowadzących i kilka informacji o kontekście kursu.

Tabela 6: Zmienne w konspekcie — role i ograniczenia

Rola w konspekcie	Zmienne	Co opisują	Ograniczenie pomiaru
Zmienna wynikowa	eval	Ogólna ocena kursu w ankiecie studenckiej; główny wynik, który interpretujemy.	Nie jest bezpośrednim pomiarem jakości nauczania. Może mieszać satysfakcję, sympatię, łatwość kursu.
Główne tropy	beauty, gender, native, minority, response.rate	Zmienne pozwalające sprawdzić różne możliwe źródła ocen z ankiety.	Każda jest tylko wskaźnikiem szerszego zjawiska i wymaga alternatywnych wyjaśnień.

Tabela 6: Zmienne w konspekcie — role i ograniczenia (*continued*)

Rola w konspekcie	Zmienne	Co opisują	Ograniczenie pomiaru
Kontekst kursu	division, credits, students, allstudents	Informacje o poziomie kursu, liczbie punktów i wielkości grupy.	Mogą zmieniać interpretację ocen; nie są pełnym opisem trudności ani organizacji zajęć.
Cechy prowadzącego	age, tenure, prof	Dodatkowe informacje o prowadzącym, przydatne jako kontekst lub wyjaśnienia poboczne.	Nie mierzą stylu prowadzenia, przygotowania dydaktycznego ani relacji ze studentami.

3. Trop i hipotezy

Każdy trop zapisujemy w tym samym porządku: pytanie, hipoteza, zmienne do użycia, dostępne dane i braki, alternatywne wyjaśnienia i plan interpretacji. Poniżej gotowy konspekt dla każdego tropu z naszej wiązki.

Trop: Atrakcyjność

Pytanie badawcze: Czy prowadzący oceniani jako atrakcyjniejsi dostają wyższe oceny kursu?

Hipoteza robocza: Wyższe `beauty` występuje z wyższym `eval`.

Zmienne do użycia: wynik: `eval`; trop: `beauty`.

Dostępne dane i braki: Mamy `beauty`, `age`, `gender` oraz cechy kursu (`division`, `credits`). Nie mamy bezpośredniej miary pewności siebie ani stylu prowadzenia.

Alternatywne wyjaśnienia:

- Atrakcyjność może być powiązana z wiekiem lub płcią.
- Studenci mogą wyżej oceniać osoby bardziej pewne siebie, a nie wygląd sam w sobie.
- Efekt może zależeć od typu kursu.

Co uwzględnić w analizie: Sprawdzić związek `beauty` z `eval`, a potem uwzględnić wiek, płeć i typ kursu jako możliwe wyjaśnienia poboczne.

Trop: Płeć

Pytanie badawcze: Czy kobiety i mężczyźni prowadzący są oceniani podobnie?

Hipoteza robocza: Średnie `eval` różni się między grupami `gender`.

Zmienne do użycia: wynik: `eval`; trop: `gender`.

Dostępne dane i braki: Mamy `gender`, `eval`, cechy kursu oraz `response.rate`. Nie mamy danych o oczekiwaniach studentów ani stylu komunikacji prowadzącego.

Alternatywne wyjaśnienia:

- Kobiety i mężczyźni mogą prowadzić inne typy kursów.

- Różnice mogą wynikać z oczekiwań studentów wobec stylu prowadzenia.
- Nierówny response rate może zmieniać obraz.

Co uwzględnić w analizie: Porównać oceny między grupami i sprawdzić, które cechy kursu oraz reprezentatywność odpowiedzi trzeba uwzględnić przy interpretacji.

Trop: Native speaker

Pytanie badawcze: Czy status native speaker wiąże się z oceną kursu?

Hipoteza robocza: Średnie **eval** różni się między **native = tak** i **native = nie**.

Zmienne do użycia: wynik: **eval**; trop: **native**.

Dostępne dane i braki: Mamy **native**, **division**, **credits** i liczebności grup. Nie mamy informacji o języku prowadzenia, poziomie trudności materiału ani doświadczeniu językowym studentów.

Alternatywne wyjaśnienia:

- Status native może mieszać się z typem kursu.
- Native speakerzy mogą uczyć innych przedmiotów albo na innym poziomie.
- Grupy mogą mieć różną liczebność.

Co uwzględnić w analizie: Sprawdzić, czy grupy różnią się oceną, oraz uwzględnić kontekst kursu i ostrożność przy nierównych liczebnościach.

Trop: Mniejszość

Pytanie badawcze: Czy prowadzący z grup mniejszościowych są oceniani inaczej?

Hipoteza robocza: Średnie **eval** różni się między **minority = tak** i **minority = nie**.

Zmienne do użycia: wynik: **eval**; trop: **minority**.

Dostępne dane i braki: Mamy **minority**, **eval** i kilka cech prowadzącego/kursu. Nie mamy danych o doświadczeniach dyskryminacji, atmosferze zajęć ani treści komentarzy studentów.

Alternatywne wyjaśnienia:

- Grupa mniejszościowa może być mało liczna — trudniej o stabilny wynik.
- Różnice mogą ujawniać się tylko w wybranych typach kursów.
- Status mniejszości może współwystępować z innymi cechami prowadzącego.

Co uwzględnić w analizie: Opisać liczebności grup, porównać oceny i sprawdzić, czy wynik nie wynika z innych cech kursu lub prowadzącego.

Trop: Response rate

Pytanie badawcze: Czy przy niskim odsetku odpowiedzi ocena kursu znaczy to samo?

Hipoteza robocza: `response.rate` występuje z `eval`.

Zmienne do użycia: wynik: `eval`; trop: `response.rate`.

Dostępne dane i braki: Mamy `response.rate`, `students`, `allstudents` i `eval`. Nie mamy informacji, kto dokładnie odpowiedział ani dlaczego część osób pominęła ankietę.

Alternatywne wyjaśnienia:

- Odpowiadają głównie osoby skrajnie zadowolone lub niezadowolone.
- Duże kursy mogą mieć niższy response rate.
- Zaangażowanie grupy może wpływać i na oceny, i na odsetek odpowiedzi.

Co uwzględnić w analizie: Sprawdzić, czy odsetek odpowiedzi wiąże się z oceną i czy wielkość kursu zmienia interpretację tego związku.

4. Plan interpretacji


1. Opiszemy zmienną wynikową i najważniejsze zmienne z tropów.
2. Sprawdzimy każdy trop osobno: czy sugeruje związek z `eval`.
3. Przy każdym tropie zapiszemy alternatywne wyjaśnienia i sprawdzimy, czy mamy dane, żeby je uwzględnić.
4. Zestawimy tropy razem, żeby ocenić, co cała wiązka mówi o celu.
5. Wniosek sformułujemy ostrożnie: dane obserwacyjne wspierają interpretację, ale nie dowodzą przyczynowości.

5 Pierwsze sprawdzenia

Test statystyczny sprawdza, czy dany trop ma oparcie w danych. Nie rozstrzyga celu — dostarcza przesłanki do jego oceny. Każdy trop dostaje wykres i test dopasowany do typu zmiennych: korelację dla zmiennych ilościowych, test t lub Mann-Whitneya dla porównania dwóch grup. Nie pytamy tylko „czy $p < 0,05$?” — pytamy, czy wynik wzmacnia trop, osłabia go, czy każe zmienić pytanie.

5.0.1 Trop: Atrakcyjność

Pytanie: Czy prowadzący oceniani jako atrakcyjniejsi dostają wyższe oceny kursu?




Zmienna	Średnia	SD	Mediana	Q1	Q3
Ocena atrakcyjności	0	0.79	-0.07	-0.66	0.55
Ocena kursu	4	0.55	4.00	3.60	4.40

Miara efektu (korelacja): $r = 0,189$ · korelacja Pearsona · $p < 0,001$

Wynik wzmacnia trop: Wynik wzmacnia trop: $r = 0,189$. To jeszcze nie dowód przyczynowy, ale dobry powód, żeby zadać kolejne pytanie.

5.0.2 Trop: Płeć

Pytanie: Czy kobiety i mężczyźni prowadzący są oceniani podobnie?




Grupa	Średnia	SD	Mediana	Q1	Q3
kobieta	3.90	0.54	3.90	3.6	4.3
mężczyzna	4.07	0.56	4.15	3.7	4.5

Miara efektu (różnica średnich): $\Delta = 0,17$ (mężczyzna – kobieta) · test t dla dwóch grup · $p = 0,001$

Wynik wzmacnia trop: Wynik wzmacnia trop: różnica średnich = 0.168. To jeszcze nie dowód przyczynowy, ale dobry powód, żeby zadać kolejne pytanie.

5.0.3 Trop: Native speaker

Pytanie: Czy status native speaker wiąże się z oceną kursu?




Grupa	Średnia	SD	Mediana	Q1	Q3
nie	3.69	0.48	3.6	3.3	4.0
tak	4.02	0.55	4.0	3.7	4.4

Miara efektu (różnica średnich): $\Delta = 0,33$ (tak – nie) · Mann-Whitney · $p = 0,001$

Wynik wzmacnia trop: Wynik wzmacnia trop: różnica średnich = 0.329. To jeszcze nie dowód przyczynowy, ale dobry powód, żeby zadać kolejne pytanie.

5.0.4 Trop: Mniejszość

Pytanie: Czy prowadzący z grup mniejszościowych są oceniani inaczej?




Grupa	Średnia	SD	Mediana	Q1	Q3
nie	4.02	0.55	4.0	3.65	4.40
tak	3.89	0.60	3.8	3.40	4.32

Miara efektu (różnica średnich): $\Delta = -0,12$ (tak – nie) · Mann-Whitney · $p = 0,072$

Wynik osłabia trop: Wynik osłabia prostą wersję tropu: różnica średnich = -0.123. To nie znaczy, że temat znika; raczej trzeba zmienić hipotezę albo pomiar.

5.0.5 Trop: Response rate

Pytanie: Czy przy niskim odsetku odpowiedzi ocena kursu znaczy to samo?



Zmienna	Średnia	SD	Mediana	Q1	Q3
Response rate (%)	74.43	16.76	76.9	62.7	87.25
Ocena kursu	4.00	0.55	4.0	3.6	4.40

Miara efektu (korelacja): $r = 0,223$ · korelacja Pearsona · $p < 0,001$

Wynik wzmacnia trop: Wynik wzmacnia trop: $r = 0,223$. To jeszcze nie dowód przyczynowy, ale dobry powód, żeby zadać kolejne pytanie.

5.1 Tablica tropów po pierwszych testach

Tabela 12: Tablica tropów — pełny obraz po pierwszych testach

Trop	Pytanie	Narzędzie	Efekt · p	Werdykt
Atrakcyjność	Czy prowadzący oceniani jako atrakcyjniejsi dostają wyższe oceny kursu?	korelacja Pearsona	$r = 0,189$ · $p < 0,001$	trop wzmocniony
Płeć	Czy kobiety i mężczyźni prowadzący są oceniani podobnie?	test t dla dwóch grup	$\Delta = 0,17$ (mężczyzna — kobieta) · $p 0,001$	trop wzmocniony
Native speaker	Czy status native speaker wiąże się z oceną kursu?	Mann-Whitney	$\Delta = 0,33$ (tak — nie) · $p 0,001$	trop wzmocniony

Mniejszość	Czy prowadzący z grup mniejszościowych są oceniani inaczej?	Mann-Whitney	$\Delta = -0,12$ (tak – nie) · $p = 0,072$	trop osłabiony
Response rate	Czy przy niskim odsetku odpowiedzi ocena kursu znaczy to samo?	korelacja Pearsona	$r = 0,223$ · $p < 0,001$	trop wzmocniony

6 Wynik nie kończy badania

Pojedynczy wynik nie odpowiada na cel. Dopiero zebrane razem tropy zaczynają coś mówić: część się wzmocniła, część osłabła. Werdykt „wzmocniony” nie znaczy „udowodniony”, a „osłabiony” nie znaczy „temat zamknięty”.

Tropy wzmocnione przez dane: Atrakcyjność, Płeć, Native speaker, Response rate

Tropy osłabione: Mniejszość

Żaden pojedynczy trop nie rozstrzyga, czy **eval** mierzy jakość. Ale wiązka pokazuje, że w ocenie z ankiety siedzi więcej niż sama jakość nauczania — i że trzeba sprawdzić te tropy jednocześnie, w jednym modelu.

6.1 Co możemy policzyć dla tropów?

Tropy zapisaliśmy osobno, żeby nie zgubić pytań. W analizie zaczynają się jednak spotykać: ta sama zmienna może być raz głównym tropem, a raz alternatywnym wyjaśnieniem dla innego tropu. Dlatego porządkujemy obliczenia w trzech warstwach: sprawdzenia pojedyncze, sprawdzenia krzyżowe między tropami i analiza łączona.

Atrakcyjność (trop wzmocniony)

Studenci mogą część oceny kursu przypisywać nie tylko jakości prowadzenia, ale też ogólnemu wrażeniu związanemu z prowadzącym.

1. **Pojedynczy trop:** Policzyć związek między **beauty** i **eval**.
2. **Tropy krzyżowe:** Sprawdzić, czy **beauty** współwystępuje z wiekiem, płcią lub typem kursu.
3. **Analiza łączona:** W modelu łączonym sprawdzić, czy związek **beauty** z **eval** pozostaje widoczny po dodaniu innych zmiennych.

Płeć (trop wzmocniony)

Oceny mogą odzwierciedlać różne oczekiwania wobec prowadzących kobiet i mężczyzn, a nie tylko jakość zajęć.

1. **Pojedynczy trop:** Policzyć różnice w **eval** między grupami **gender**.
2. **Tropy krzyżowe:** Sprawdzić, czy grupy **gender** różnią się typem kursów, response rate albo innymi cechami prowadzącego.
3. **Analiza łączona:** W modelu łączonym potraktować **gender** jako osobny trop oraz możliwe wyjaśnienie poboczne dla innych efektów.

Native speaker (trop wzmocniony)

Status językowy prowadzącego może wpływać na odbiór zajęć albo mieszać się z typem kursów, które prowadzi dana grupa.

1. **Pojedynczy trop:** Policzyć różnice w `eval` między `native = tak` i `native = nie`.
2. **Tropy krzyżowe:** Sprawdzić, czy status `native` współwystępuje z poziomem kursu, credits albo liczebnością grup.
3. **Analiza łączona:** W modelu łączonym sprawdzić, czy status `native` wnosi informację po uwzględnieniu innych cech kursu i prowadzącego.

Mniejszość (trop osłabiony)

Oceny mogą zawierać element nierównego traktowania albo stereotypów, ale taki trop wymaga szczególnie ostrożnej interpretacji.

1. **Pojedynczy trop:** Policzyć różnice w `eval` między `minority = tak` i `minority = nie` oraz opisać liczebności grup.
2. **Tropy krzyżowe:** Sprawdzić, czy status `minority` współwystępuje z płcią, statusem `native`, typem kursu lub innymi cechami.
3. **Analiza łączona:** W modelu łączonym traktować ten trop ostrożnie: jako sygnał do interpretacji, nie jako dowód mechanizmu.

Response rate (trop wzmocniony)

Ocena kursu może wyglądać inaczej, gdy ankietę wypełnia mała albo selektywna część studentów.


1. **Pojedynczy trop:** Policzyć związek między `response.rate` i `eval`.
2. **Tropy krzyżowe:** Sprawdzić, czy `response.rate` wiąże się z wielkością kursu (`students`, `allstudents`) albo typem kursu.
3. **Analiza łączona:** W modelu łączonym sprawdzić, czy response rate zmienia interpretację pozostałych tropów.

6.2 Zmienne zakłócające

Pierwsze pytanie po każdym wyniku brzmi: czy to nie zasługa czegoś innego? Zmienna Z może mieszać w interpretacji, jeśli wiąże się jednocześnie z predyktorem i z wynikiem. Prześledźmy to na przykładzie płci, a potem zbiorczo.

Przykład: czy płeć zakłóca relację beauty → eval?

Płeć jest kandydatem na zakłócacz tylko wtedy, gdy wiąże się i z atrakcyjnością (predyktorem), i z oceną kursu (wynikiem). Poniżej oba związki naraz:



Płeć wiąże się z atrakcyjnością (różnica median = 0.181) i z oceną kursu (różnica median = 0.25). Oba związki są wyraźne — płeć jest kandydatem na zmienną zakłócającą. Relacji beauty → eval nie można czytać bez uwzględnienia płci.

6.2.1 Tabela zakłócaczy

Zmienna jest kandydatem na zakłócacz, gdy wiąże się i z **beauty** , i z **eval** jednocześnie.

Tabela 13: Kandydaci na zmienne zakłócające (dla tropu beauty)

Zmienna	Związek z beauty	Związek z eval	Werdykt
Płeć	różnica median = 0.181	różnica median = 0.25	kandydat na zakłócacz
Wiek prowadzącego	$r = 0.298$	$r = 0.052$	nie zakłóca głównej relacji
Tenure track	różnica median = 0.029	różnica median = 0.2	nie zakłóca głównej relacji
Mniejszość	różnica median = 0.016	różnica median = 0.2	nie zakłóca głównej relacji
Native speaker	różnica median = 0.161	różnica median = 0.4	kandydat na zakłócacz
Punkty ECTS/credits	różnica median = 0.466	różnica median = 0.7	kandydat na zakłócacz
Poziom kursu	różnica median = 0.024	różnica median = 0.1	nie zakłóca głównej relacji

Brak zakłócenia to nie brak znaczenia. Wiek wiąże się silnie z atrakcyjnością, ale słabo z oceną — to podpowiada, że **beauty** może częściowo mierzyć wiek, czyli być jego *proxy*. Pytanie „czy uroda wpływa na ocenę, czy jest tylko zasłoną dla wieku?” zostaje otwarte.

Wniosek pośredni: jeśli choć jedna zmienna wiąże się i z **beauty** , i z **eval** , prosty test nie wystarczy — trzeba uwzględnić te zmienne jednocześnie. To jest dokładnie zadanie dla modelu kontrolnego.

Czego brakuje w danych: efekty uczenia się przed i po kursie; trudność kursu i obciążenie pracą; oczekiwana ocena; obowiązkowość kursu; styl prowadzenia; powody braku odpowiedzi w ankiecie. Wynik wskazuje kolejne pytanie — nie zamyka tematu.

7 Model kontrolny


W rozdziale 5 sprawdzaliśmy tropy pojedynczo. Teraz sprawdzamy je jednocześnie: czy efekt utrzymuje się, gdy kontrolujemy pozostałe? Regresja wieloczynnikowa pozwala zapytać wprost: czy trop związany z **beauty** pozostaje widoczny, gdy jednocześnie uwzględnimy wiek, płeć, status native speaker, poziom kursu i response rate?

7.1 Seria modeli kontrolnych


Dodajemy kontrole warstwami i patrzymy, co dzieje się ze współczynnikiem przy **beauty**: czy słabnie, czy się trzyma.

Tabela 14: Seria modeli kontrolnych — efekt beauty pod kolejnymi kontrolami

Model	beauty	p (beauty)	adj.R ²	AIC
M1: beauty	0.133	< 0,001	0.034	757
M2: + cechy osoby	0.136	< 0,001	0.094	732
M3: + kontekst kursu	0.156	< 0,001	0.141	710
M4: + response rate	0.134	< 0,001	0.178	690



Model M4 — wszystkie predyktory



Rola modelu: model nie zastępuje sformułowania pytania. Wymaga wcześniejszych hipotez, alternatywnych wyjaśnień i poprawnego pomiaru — dopiero wtedy jego wynik da się sensownie zinterpretować.

Granica danych obserwacyjnych: jeśli efekt beauty przeżywa kontrolę, rodzi to kolejne pytanie — czy to przyczynowość? Dane obserwacyjne pokazują współwystępowanie, nie przyczynę. To granica, której ten zbiór nie przekroczy, i trzeba ją uczciwie zapisać we wniosku.

8 Od konspektu do wniosku

Konspekt powstał przed analizą. Po sprawdzeniach wracamy do niego i dopisujemy, co dane zmieniły w interpretacji celu.

8.1 Co dopisać po analizie?

Po pierwszych sprawdzeniach konspekt nie znika. Staje się szkieletem raportu: przy każdym tropie dopisujemy wynik, interpretację, ograniczenie i pytanie, które wynika z analizy.

Krok	Co dopisujemy	Przykład dla naszych danych
1	Wyniki przy tropach — które wzmacniają, które osłabiają. Nie zmieniaj celu tylko dlatego, że jeden wynik jest ciekawy.	Część tropów pomaga interpretować eval , ale żaden pojedynczy wynik nie rozstrzyga całego celu.
2	Interpretacja celu — zbierz tropy razem i napisz, co cała wiązka mówi o głównym pytaniu.	Ocena z ankiety wygląda raczej jak wskaźnik mieszany niż czysta miara jakości nauczania.
3	Ograniczenia — nazwij, czego dane nie pozwalają stwierdzić. To część jakości projektu, nie porażka analizy.	Dane obserwacyjne pokazują współwystępowanie, ale nie pozwalają rozstrzygnąć przyczynowości.
4	Następny krok — jak rozwinąć projekt: jakie dane, pomiary lub porównania byłyby potrzebne.	Przydałyby się komentarze z ankiet, dane o typie zajęć i lepszy pomiar jakości nauczania.

8.2 Zdanie, które warto mieć w raporcie

„Nasze dane wspierają interpretację X, ale nie pozwalają rozstrzygnąć przyczynowości, ponieważ...”

To nie osłabia pracy. To pokazuje, że autorzy rozumieją granice własnego badania. Właśnie taki standard chcemy przenieść do projektów grupowych: nie metoda dla metody, tylko badawcza historia, w której statystyka jest narzędziem do ostrożnego dochodzenia do odpowiedzi.

8.3 Domknięty projekt: cel + wiązka + werdykty

Cała droga w jednym kadrze: cel badawczy, tropy, dane i ostrożne werdykty. Wasz raport ma wracać do konspektu, który powstał przed analizą.

Tabela 16: Tablica tropów — domknięty projekt

Trop	Pytanie	Narzędzie	Efekt · p	Werdykt
Atrakcyjność	Czy prowadzący oceniani jako atrakcyjniejsi dostają wyższe oceny kursu?	korelacja Pearsona	$r = 0,189 \cdot p < 0,001$	trop wzmocniony
Płeć	Czy kobiety i mężczyźni prowadzący są oceniani podobnie?	test t dla dwóch grup	$\Delta = 0,17$ (mężczyzna — kobieta) · p 0,001	trop wzmocniony

Native speaker	Czy status native speaker wiąże się z oceną kursu?	Mann-Whitney	$\Delta = 0,33$ (tak – nie) · p 0,001	trop wzmocniony
Mniejszość	Czy prowadzący z grup mniejszościowych są oceniani inaczej?	Mann-Whitney	$\Delta = -0,12$ (tak – nie) · p 0,072	trop osłabiony
Response rate	Czy przy niskim odsetku odpowiedzi ocena kursu znaczy to samo?	korelacja Pearsona	$r = 0,223$ · p < 0,001	trop wzmocniony